

Zakariae YAHYA

À la recherche d'un stage PFE en tant que Junior Data Engineer et IA engineer

✉ zakariae.yh@gmail.com

☎ +212 648151446

🌐 zakariae yahya

🔄 zakariaeyahya

📍 Mobilité nationale



PROFIL

Étudiant en 5ème année à l'ENSA de Tétouan, spécialisé en Data Science et Intelligence Artificielle. Passionné par le développement de solutions innovantes en data science et l'optimisation de l'exploitation des données massives, je recherche actuellement un stage PFE pour appliquer et développer mes compétences dans un cadre professionnel.

FORMATION ACADÉMIQUE

5ème année spécialisée en Data Science et IA, ENSA Tétouan

2021 – Actuellement

Baccalauréat en sciences mathématiques, Lycée Qualifiant Jaber Ibn Hayyan

2019 – 2020

EXPÉRIENCES PROFESSIONNELLES

Stage - Développeur Fullstack IA – Projet BrainBoost (Alternance), Marketing confort

02/2025 – 07/2025

- Conception et développement des interfaces web et mobile dédiées aux parents (suivi de la progression des enfants) et aux administrateurs (configuration des assistants IA).
- Développement du back-end pour la gestion des assistants IA, des utilisateurs et des contenus pédagogiques.
- Intégration de l'intelligence artificielle générative pour fournir des réponses guidées, personnalisées et filtrées selon des règles éducatives précises.
- Mise en place d'un système de vectorisation des contenus et de suivi des performances des modèles IA.
- Participation active à une équipe agile avec réunions hebdomadaires techniques/fonctionnelles.
- Technologies : Jira, Agile, Django, LangChain, LlamaIndex, MLflow, sentence-transformers, TypeScript, React, React Native, Spring Boot, PostgreSQL, Qdrant, Docker, Kubernetes, GitLab CI/CD, AWS, Postman, Apache Maven

Stage - Data Scientist, DIGITAL PLACE

06/2024 – 09/2024

- Conception et déploiement d'un prototype mobile avec une interface vocale et textuelle en français et en dialecte marocain (darija), pour faciliter l'interaction client dans un contexte multilingue.
- Participation active aux réunions fonctionnelles et techniques avec l'équipe de développement et les interlocuteurs métier du client bancaire, afin d'adapter l'assistant aux besoins réels des utilisateurs.
- Technologies : Agile, Slack, LLM, RAG, LangChain, Groq API, FastAPI, Transformers, PyTorch, TensorFlow, sentence-transformers

PROJETS PERSONNEL | ACADÉMIQUE

ASSISTANT ÉDUCATIF

- Développement d'un assistant IA multimodal pour le soutien scolaire personnalisé.
- Implémentation d'un système RAG avec vectorisation des ressources éducatives
- Technologies : Python, FastAPI, Streamlit, LlamaIndex, Qdrant, LangChain, Whisper, MLflow, Postman.

SYSTÈME ANTI-SOMNOLENCE

2023

- Développement d'un système de détection de somnolence en temps réel, capable d'identifier les signes de fatigue avec une latence inférieure à 100 ms et une précision de 95%.
- Le système intègre une alerte intelligente qui a permis de réduire les faux positifs de 80%.
- Technologies : OpenCV, TensorFlow, NumPy, Matplotlib, scikit-learn, Streamlit, Pillow, Pandas, Plotly, Pygame.

CLASSIFICATEUR DE MUSIQUE MAROCAINE

- Modèle hybride CNN et RNN-LSTM classifiant 8 genres de musique avec 90% de précision
- Base de données personnalisée de 10K+ échantillons audio marocains
- Technologies : TensorFlow, Keras, Librosa, FastAPI, Streamlit

Pipeline d'Analyse E-commerce sur AWS avec Architecture Medallion

- Mise en place d'une solution d'analyse automatisée pour une entreprise e-commerce.
- Automatisation de la collecte, du traitement et de la structuration des données depuis une base transactionnelle vers un entrepôt de données.
- Création de tableaux de bord interactifs.
- Technologies : AWS DMS, RDS MySQL, Glue, Redshift, S3, Lambda, Step Functions, QuickSight, Python, Parquet

Analyse des infrastructures sportives

- Conception d'un pipeline ETL complet avec automatisation du traitement des données collectées sur le web.
- Création d'un tableau de bord interactif pour la visualisation et l'aide à la décision.
- Technologies : Python, BeautifulSoup, Apache Airflow, Power BI, Snowflake, AWS S3, Docker.

Analyse de la transformation digitale de la SNCF

- Étude de cas réel sur la modernisation des systèmes d'information et l'impact de la digitalisation sur la prise de décision et la gouvernance IT.
- Sujets abordés : IT management, données de marché, IoT prédictif, big data, transformation organisationnelle.

Analyse Intégrée des Données Socio-Économiques, Éducatives et Criminelles

- Analyse de datasets multi-sources (démographie, criminalité, éducation) à l'aide de requêtes SQL complexes.
- Extraction d'insights sur les dynamiques sociales et économiques.
- Technologies : Python, Scikit-learn, Pandas, SQL et Matplotlib/Seaborn.

ASSISTANT IA MULTIMODAL

- Réalisation d'un système intelligent d'analyse multilingue - Intégration de fonctionnalités : analyse de code, traitement PDF, chat vocal
- Implémentation de modèles LLM via API Groq
- Technologies : FastAPI, Streamlit, Transformers, Seamless M4T Large, Llama 3.1 70b, LangChain.

Analyse de la Qualité de l’Air en Inde

- Étude des données sur la pollution atmosphérique, création de visualisations (cartes géographiques, graphiques en barres) pour analyser les niveaux de pollution par région.
- Développement d’un tableau de bord interactif pour la prise de décision.
- **Technologies** : R, Power BI.

Système automatisé de correspondance CV-offres

- Développement d’un moteur d’analyse sémantique intelligent pour l’automatisation du recrutement.
- **Technologies**: FastAPI, Streamlit, sentence-transformers, LangChain,LLM.

ANALYSEE LA DBASE DE DONNÉES SPORTIVE NBA

- Développement d’un système de gestion de données sportives avec modélisation des relations entre joueurs, équipes et entraîneurs
 - Implémentation de requêtes avancées pour l’analyse des performances et contrats des joueurs (IMC, salaires, statistiques de match)
- Technologies : Neo4j, Cypher Query Language

Assistant IA Multilingue pour Analyse et Interrogation de Documents

Développement une application web de traitement audio et texte multilingue. Intégration des modèles de traduction, transcription et synthèse vocale et créé une API RESTful avec FastAPI pour le traitement backend. Utilisation des technologies telles que Python, FastAPI, Streamlit et Transformers.

Plateforme Web de Traduction Multimédia Intelligente

Développement d’une application web pour la traduction de texte, PDF, vidéo et audio. Intégration des modèles de traduction, transcription et synthèse vocale et créé une API RESTful avec FastAPI pour le traitement backend. Utilisation des technologies telles que Python, FastAPI, Streamlit et Transformers.

DÉTECTION DE DISCOURS HAINEUX SUR TWITTER

- Conception d’un système NLP pour l’identification automatique des contenus toxiques avec 98% de précision
- Technologies : Scikit-learn, Pandas, NLTK, TF-IDF Vectorizer

PRÉDICTION DIABÈTE

- Modèle ensemble atteignant 92.5% F1-score sur prédiction précoce du diabète
 - Pipeline automatisé de prétraitement et validation croisée
- Technologies**: Python, Scikit-learn, Matplotlib/Seaborn.

IBM Data Science

Projet d’Analyse Prédictive du Marché Immobilier : Développement des modèles de régression (linéaire, Ridge, polynomiale) pour prédire les prix du marché immobilier. J’ai utilisé des technologies telles que Python et Scikit-learn.

Projet de Prévision Météorologique :Création d’un système de prédiction de pluie qui compare cinq modèles ML (dont KNN et SVM). Utilisation des technologies telles que Python et Scikit-learn.

Projet d’Exploration et d’Analyse de Données Financières Développement d’un outil d’analyse pour Tesla et GameStop en utilisant l’API yfinance et web scraping. Création des visualisations interactives des cours d’actions et des revenus.

Mini Projet d’Analyse de Données - Chicago Étude des datasets multiples (recensement, écoles, criminalité) avec des requêtes SQL complexes. Extraction des insights sur les tendances socio-économiques, éducatives et criminelles. Utilisation des technologies telles que Python, Scikit-learn, Pandas, SQL et Matplotlib/Seaborn.

Autres Projets

COMPÉTENCES

Big Data & Data Engineering

- Bases de données** : SQL (MySQL, Oracle), NoSQL.
- Cloud & Big Data** : AWS (S3, Lambda, Glue, IAM, EMR, Redshift), Apache Spark, Hadoop, Snowflake, SQL Server
- Orchestration & Pipelines**: Apache Airflow , AWS Step Functions .
- Indexation & Vector Search** : Qdrant, ChromaDB

Analyse décisionnelle & Reporting

- **Outils** : Power BI, Tableau, Excel , Amazon QuickSight.
- **Modélisation** : Conception de data marts, architecture Medallion (Bronze, Silver, Gold)

Modélisation et Conception

UML, Merise

Méthodologies & Transverses

- **Conception** : UML, Merise
- **Communication** : Français, Anglais, Arabe – Excellent relationnel
- **Gestion de projet** : Spécifications fonctionnelles, développement, tests .

Extraction et Traitement de Données

CERTIFICATS

IBM Data Science | Microsoft Data Analysis and Visualization with Power BI

LANGUES

Arabe Langue maternelle	Anglais Courant	Français Courant
-----------------------------------	---------------------------	----------------------------