



ZAKARIAE YAHYA AI Engineer Junior – Orchestration d’agents IA, workflows GenAI, RAG, MLOps

✉ zakariae.yh@gmail.com 📞 +212 648151446
📍 Maroc | Remote Europe 🌐 zakariae yahya
🐙 github.com/zakariaeyahya

Profil
AI Engineer junior orienté orchestration d’agents IA et industrialisation de workflows GenAI pour des usages métier et techniques. Expérience concrète en conception de systèmes multi-agents, RAG, automatisation, backend Python, observabilité et déploiement cloud, avec capacité à structurer des processus reproductibles et à collaborer avec des équipes de développement autour d’outils IA.

Formation Académique
Ingénierie en Big Data & Intelligence Artificielle, ENSA Tétouan 2021 – 2026

Expérience Professionnelle
Stage PFE – AI Software Engineer, Banque Centrale Populaire – Architecture et Innovation Groupe 02/2026 – 08/2026 / Casablanca

- Développement de deux modèles de scoring fraude avec AUC 0,91 et 0,94, réentraînement quotidien automatisé, réduction des faux positifs de 15 % et tracking MLflow.
- Conception d’un pipeline temps réel Kafka / Spark / Airflow pour la détection de fraude sur 1M+ transactions intra-bancaires par jour avec latence inférieure à 100 ms.
- Mise en place d’un monitoring de dérive et de performance avec Prometheus / Grafana, déploiement sur Azure AKS et sécurisation des accès via Red Hat SSO / Keycloak.
- Conception d’une architecture multi-agents avec MCP, LangGraph et LLM pour assister les analystes fraude, structurer le workflow d’investigation et générer des rapports métier reproductibles.

Stack : Python, Kafka, Spark, Airflow, MLflow, Docker, Azure AKS, Keycloak, Prometheus, Grafana, LangChain, LangGraph, MCP, LLM
Stage – AI Software Engineer, Izemx 02/2025 – 01/2026 / Remote

- Projet IAVIA – optimisation d’un système RAG pour la recherche documentaire**
- Conception et optimisation d’un workflow RAG avec amélioration de la pertinence de 35 % et réduction de la latence de 3,5 s à 0,9 s.
 - Orchestration de l’ingestion documentaire multi-sources et des interactions utilisateurs via Slack / Teams, avec réduction du temps d’indexation de 60 %.
 - Structuration d’un process de recherche documentaire assistée par IA avec batching, cache intelligent et optimisation d’inférence réduisant la charge CPU / GPU de 55 %.

Stack : Python, LangChain, Qdrant, FastAPI, Redis, Docker, n8n, RAG, vector search

- Projet BrainBoost – assistants IA et RAG éducatif**
- Conception d’une application éducative avec assistants IA pour accompagner les enfants dans leurs exercices et devoirs.
 - Amélioration de la pertinence du module RAG de 28 %, développement du backend et des interfaces des assistants IA.
 - Mise en place d’un monitoring des modèles réduisant les erreurs de réponse de 20 %.

Stack : Python, PostgreSQL, Docker, Django, React, Spring Boot, LangChain, MLflow, Qdrant

- Projet Zyra – système IA temps réel pour flux et décision**
- Développement d’un pipeline Big Data temps réel pour ingestion et traitement de flux de marchés financiers.
 - Obtention d’une latence inférieure à 250 ms, amélioration de la fiabilité de 20 % et réduction des erreurs d’exécution de 25 %.

Stack : Python, Redis Streams, PostgreSQL, Grafana, Docker

- Stage – Data Scientist, DIGITAL PLACE** 06/2024 – 09/2024 / Tanger, Maroc
- Conception d’un assistant conversationnel vocal et textuel bilingue, avec optimisation du temps de réponse de 40 %.
 - Développement et intégration des composants IA et backend pour améliorer la qualité et la fluidité des interactions.

Stack : Python, LLM, RAG, LangChain, FastAPI, Docker, Slack

Projets
Plateforme IA d’analyse de sentiment crypto en temps réel

- Orchestration Airflow d’un pipeline Bronze / Silver / Gold ingérant Reddit et Kaggle, avec nettoyage et structuration de données.
- Fine-tuning d’un modèle RoBERTa sur 19M de tweets pour la classification de sentiment, avec accuracy 0,86.
- Déploiement d’un système RAG temps réel sur Qdrant avec interactions vocales speech-to-speech.

Stack : Python, Apache Airflow, Docker, PostgreSQL, Qdrant, Hugging Face Transformers, PyTorch

- SAFIA – plateforme de planification voyage multi-agents**
- Développement d’une architecture multi-agents avec orchestrateur, sous-agents spécialisés et MCP pour générer des plans de voyage personnalisés.
 - Conception de workflows agents reproductibles pour la génération d’itinéraires, recommandations locales, estimation budgétaire et optimisation des trajets.
 - Développement d’une API Python / FastAPI exposant les services IA, les workflows agents et la génération de brochures PDF.

Stack : Python, FastAPI, LangGraph, LangChain, MCP, PostgreSQL, AWS EC2, Docker

Compétences
Agentic AI / GenAI : orchestration d’agents IA, systèmes multi-agents, MCP, LangChain, LangGraph, RAG, prompt engineering, évaluation LLM, vector search, Qdrant

Workflow & Delivery : automatisation de processus, workflows reproductibles, intégration Slack / Teams, documentation technique, collaboration avec équipes dev, veille outillage IA

Backend & Production : Python, FastAPI, Django, Spring Boot, PostgreSQL, Redis, Docker, Kubernetes, APIs, CI/CD, performance, sécurité

Data / MLOps / Cloud : Kafka, Spark, Airflow, MLflow, monitoring de dérive, Prometheus, Grafana, Azure AKS, AWS EC2

Langues
Arabe Langue maternelle **Français** Compétence professionnelle **Anglais** Compétence professionnelle