



ZAKARIAE YAHYA Data Engineer Junior – ETL/ELT, Spark, Airflow, Databricks, Streaming

✉ zakariae.yh@gmail.com 📞 +212 648151446
📍 Maroc | Remote Europe 🌐 zakariae yahya
🐙 github.com/zakariaeyahya

Profil
Data Engineer junior spécialisé dans la conception de pipelines batch et temps réel, l'ETL/ELT, l'orchestration et les architectures Lakehouse. Expérience pratique sur Kafka, Spark, PySpark, Airflow, Azure Databricks, AWS Glue, PostgreSQL et cloud data platforms. Intéressé par la qualité des données, la fiabilité, le monitoring, la performance et la mise en production de solutions Data à grande échelle.

Formation Académique
Ingénierie en Big Data & Intelligence Artificielle, ENSA Tétouan 2021 – 2026

Expérience Professionnelle
Stage PFE – Data Engineer, Banque Centrale Populaire – Architecture et Innovation Groupe 02/2026 – 08/2026 | Casablanca
• Développement d'un pipeline temps réel Kafka / Spark traitant 1M+ transactions intra-bancaires par jour avec latence bout-à-bout inférieure à 100 ms.
• Automatisation des traitements et des workflows avec Airflow, structuration des données dans PostgreSQL / Redis et exposition de datasets exploitables pour les équipes métier.
• Déploiement des services data sur Azure AKS, monitoring Prometheus / Grafana, sécurisation des accès via Red Hat SSO / Keycloak et bonnes pratiques d'observabilité.
• Contribution à l'industrialisation d'une plateforme data temps réel intégrant ingestion, traitement distribué, scoring et supervision de production.

Stack : Python, Kafka, Spark, PySpark, Airflow, PostgreSQL, Redis, Docker, Azure AKS, Keycloak, Prometheus, Grafana, GitLab CI/CD
Stage – AI Software Engineer, Izemx 02/2025 – 01/2026 | Remote

Projet IAVIA – ingestion documentaire et optimisation de pipelines
• Orchestration de l'ingestion documentaire multi-sources (Google Drive, S3, SharePoint) et des interactions utilisateurs, avec réduction du temps d'indexation de 60 %.
• Implémentation de mécanismes de batching, cache et optimisation de pipeline réduisant la charge CPU / GPU de 55 %.

Stack : Python, FastAPI, Redis, Docker, n8n, S3, data ingestion
Projet Zyra – pipeline Big Data temps réel pour flux financiers
• Développement d'un pipeline temps réel pour ingestion, traitement et monitoring de flux de marchés financiers.
• Obtention d'une latence de streaming inférieure à 250 ms, amélioration de la fiabilité de 20 % et réduction des erreurs d'exécution de 25 %.

Stack : Python, Redis Streams, PostgreSQL, Grafana, Docker, streaming data
Stage – Data Scientist, DIGITAL PLACE 06/2024 – 09/2024 | Tanger, Maroc
• Développement et intégration de composants data et backend pour un assistant conversationnel bilingue, avec optimisation du temps de réponse de 40 %.

Stack : Python, FastAPI, Docker

Projets
Pipeline Data Engineering End-to-End sur Azure Databricks
• Automatisation d'un pipeline Lakehouse e-commerce Bronze / Silver / Gold traitant plusieurs datasets, dont 10k+ produits.
• Mise en place d'une ingestion incrémentale avec Auto Loader, checkpoints, Databricks Workflows, tables Silver nettoyées et modèle Gold analytique avec dimensions, faits et upserts Delta.

Stack : Azure Databricks, ADLS Gen2, PySpark, Delta Lake, Unity Catalog, Auto Loader, Delta Live Tables, Lakeflow, SQL
Pipeline d'Analyse E-commerce sur AWS avec Architecture Medallion
• Conception d'un pipeline ETL / ELT de bout en bout : Amazon RDS MySQL vers AWS DMS, Amazon S3 Bronze / Silver, AWS Glue / PySpark, Amazon Redshift et orchestration via Step Functions.
• Création de dashboards interactifs pour l'analyse métier et la restitution des KPIs.

Stack : AWS DMS, S3, Glue, Step Functions, Redshift, QuickSight, RDS MySQL, Python, PySpark, SQL
Plateforme IA d'analyse de sentiment crypto en temps réel
• Orchestration Airflow d'un pipeline Bronze / Silver / Gold ingérant Reddit et Kaggle, avec nettoyage, structuration et préparation de données.
• Industrialisation d'un flux de données pour entraînement, recherche et exploitation analytique.

Stack : Apache Airflow, PostgreSQL, Docker, Python, data pipeline

Compétences
Data Engineering : ETL, ELT, batch processing, streaming, Kafka, Spark, PySpark, Airflow, Databricks, Delta Lake, Auto Loader, Delta Live Tables, Lakehouse, Medallion, ingestion, orchestration, data pipelines
Data Platforms & Cloud : Azure Databricks, ADLS Gen2, Azure, AWS, S3, Glue, Redshift, RDS, PostgreSQL, Redis, SQL
Production & Qualité : tests, validation, monitoring, observability, Prometheus, Grafana, optimisation, documentation, CI/CD, Git, Docker, Kubernetes
Backend : Python, FastAPI, APIs, intégration de services, automatisation, performance, sécurité

Langues
Arabe Langue maternelle **Français** Compétence professionnelle **Anglais** Compétence professionnelle