

Zakariae YAHYA

Zakariae YAHYA — Stage PFE | AI Engineer & LLM Specialist – Février 2026

✉ zakariae.yh@gmail.com 📞 +212 648151446 🌐 zakariae yahya 🔄 zakariaeyahya 📍 Mobilité nationale

🔗 YAHYA Zakariae



PROFIL

Étudiant ingénieur en Data & IA, je me spécialise dans l'IA générative et le MLOps. Fort de 10 mois d'expérience, j'ai conçu des architectures scalables, optimisé des systèmes RAG (-96% de latence) et industrialisé des modèles via Docker, Kafka et MLflow. Je recherche un stage de fin d'études pour contribuer au déploiement de solutions IA robustes et à impact pour vos clients.

FORMATION ACADÉMIQUE

Ingénierie en Sciences des Données, Big Data & Intelligence Artificielle, ENSA Tétouan 2021 – Actuellement

EXPÉRIENCES PROFESSIONNELLES

Stage – Data Scientist, Izemx 02/2025 – En cours | Paris , France

Projet 3: IAVIA : Optimisation du système RAG pour la recherche documentaire :

- Optimisation d'un pipeline de recherche hybride (Vector Search + BM25), réduisant la latence des requêtes de -96 % grâce à l'ajout d'un caching multi-niveaux.
- Conception d'un pipeline d'ingestion et de vectorisation PDF avec chunking intelligent et embeddings GPU, accélérant le traitement documentaire de +80 %.
- Amélioration de la pertinence du système RAG via hybridation sémantique/lexicale et reranking, augmentant la précision des réponses de +40 %.
- Optimisation de l'indexation Qdrant avec traitement parallèle par batch, réduisant l'usage mémoire de -75 % et augmentant la vitesse d'indexation de +350 %.

Projet 2 : Zyra – Plateforme d'investissement crypto autonome

Développement et déploiement d'un pipeline Big Data temps réel pour l'ingestion et le traitement de flux de marchés financiers.

- Conçu et déployé un pipeline ETL distribué (Python, Redis, PostgreSQL, Docker) capable de traiter 5k+ transactions/minute.
- Architecturé une solution event-driven (Kafka / Redis Streams) garantissant la consistance et la résilience des flux de données.
- Mis en place un système de monitoring & alerting (Grafana, CloudWatch) pour la détection d'anomalies en temps réel.

Projet 1 : BrainBoost – Plateforme éducative intelligente

Conception d'une plateforme web IA générative intégrant un système de question-réponse contextuel.

- Architecturé et déployé une solution RAG complète (LangChain, Qdrant) avec chunking intelligent et prompt engineering, diminuant le temps de réponse de 60% tout en augmentant la précision de 45%. Implémenté A/B testing et monitoring des modèles via MLflow pour optimisation .
- Développé une plateforme full-stack multi-interface (Django, React, Spring Boot) adoptée avec 98 % de satisfaction utilisateur.
- Optimisé la scalabilité et la latence du traitement de 500+ contenus/semaine, avec suivi de performance via MLflow.

Environnement technique : Python, Redis, PostgreSQL, Grafana, Docker, Django, React, Spring Boot, LangChain, LlamaIndex, MLflow, Qdrant.

Stage - Data Scientist, DIGITAL PLACE 06/2024 – 09/2024 | Tanger ,Maroc

- Conçu un assistant client vocal et textuel (français & darija) basé sur des modèles LLM et RAG multilingues, optimisant le temps de réponse de 40 %.
- Intégré une architecture LangChain + FastAPI connectée à Groq API, avec gestion des embeddings via Transformers et SentenceTransformers.
- Participé à la mise en production et au test pilote du système sous méthodologie Agile (Scrum).

Environnement technique : LLM, RAG, LangChain, FastAPI, Groq API, PyTorch, TensorFlow, Transformers, Slack

PROJETS

ASSISTANT ÉDUCATIF

- Développement d'un assistant IA multimodal pour le soutien scolaire personnalisé avec tableau de bord analytique (Grafana) pour le suivi des performances utilisateurs et l'optimisation du modèle.
- Automatisation de l'analyse et de l'organisation des ressources éducatives, avec un suivi de la performance afin d'améliorer en continu les réponses.
- Technologies: Python, FastAPI, Streamlit, LlamaIndex, Qdrant, LangChain, Whisper, MLflow, Postman.

CLASSIFICATEUR DE MUSIQUE MAROCAINE

- Développement d'un modèle hybride CNN-LSTM pour la classification de 8 genres de musique marocaine avec 90% de précision
- Création d'une base de données personnalisée de 10k+ échantillons audio avec preprocessing et feature extraction (Librosa)
- Déploiement du modèle via API FastAPI avec interface Streamlit pour des prédictions en temps réel

Technologies: TensorFlow, Keras, Librosa, FastAPI, Streamlit

COMPÉTENCES

MLOps & Data Infrastructure :

- Containerization & Orchestration : Docker, Kubernetes
- Data Pipelines : Kafka, Redis Streams, Airflow
- Monitoring & Observability : Grafana, CloudWatch, MLflow
- CI/CD : GitLab, GitHub Actions, automated testing

AI & Machine Learning :

- LLM & RAG : LangChain, LlamaIndex, Hugging Face Transformers
- Model optimization : fine-tuning, LoRA, prompt engineering
- Vector databases : FAISS, Qdrant, ChromaDB
- Deep Learning : TensorFlow, PyTorch, Keras

Backend Development & APIs :

- Web frameworks : FastAPI, Django, Spring Boot
- API design & REST principles
- Frontend integration : React, Streamlit, React native
- API testing : Postman

Languages & Core Skills :

- Languages : Python (expert), Java
- Version control : Git, GitHub, GitLab
- Agile : Scrum, sprint planning, code reviews

ACTIVITÉS PARASCOLAIRES

Membre de l'équipe d'organisation du Forum ENSA TETOUAN et Moroccan Microsoft Community

LANGUES

Arabe	Anglais	Français
Langue maternelle	Courant	Courant